



Finanzas en R

Notebook 02

Sebastián Egaña Santibáñez

Nicolás Leiva Díaz

Enlaces del profesor

 <https://segana.netlify.app>

 <https://github.com/sebaegana>

 <https://www.linkedin.com/in/sebastian-egana-santibanez/>

Agregación y unión

Agregación

Corresponde a cuando generamos métricas de un set de datos en base a alguna variable de agrupamiento. En este sentido, la métrica básica corresponde a conteos, pero también podemos generar promedios, máximos, mínimos, etc.

Leemos la data presente en el siguiente repositorio:

[Enlace acá](#)

Utilizamos el set de datos star.

1. Cargamos las librerías:

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.1.4      v readr      2.1.5
v forcats    1.0.0      v stringr    1.5.1
v ggplot2    3.5.2      v tibble     3.3.0
v lubridate  1.9.4      v tidyr      1.3.1
v purrr      1.0.4
```

```
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(httr)
```

```
library(readxl)
```

2. Con el siguiente código, podemos leer directamente el archivo:

```
# Define the URL for the raw Excel file
url <- "https://raw.githubusercontent.com/stringfestedata/advancing-into-analytics-book/main/data/star.csv"

# Get the data from the URL
response <- httr::GET(url)

# Ensure the response status is 200 (OK)
if (response$status_code == 200) {
  # Read data from the raw binary content
```

```

temp_file <- tempfile(fileext = ".xlsx")
writeBin(httr::content(response, "raw"), temp_file)
data <- readxl::read_excel(temp_file)
# Optionally, delete the temporary file after reading
unlink(temp_file)
# Use the data
print(head(data))
} else {
  print("Failed to download file: HTTP status code is not 200")
}

```

```

# A tibble: 6 x 8
  tmathssk treadssk classk          totexpk sex  freelunk race  schidkn
    <dbl>    <dbl> <chr>          <dbl> <chr> <chr>    <chr>    <dbl>
1     473     447 small.class          7 girl  no      white     63
2     536     450 small.class         21 girl  no      black     20
3     463     439 regular.with.aide    0 boy  yes      black     19
4     559     448 regular         16 boy  no      white     69
5     489     447 small.class          5 boy  yes      white     79
6     454     431 regular          8 boy  yes      white      5

```

Otro enfoque podría ser descargarlo y leerlo desde alguna carpeta.

Generamos una agrupación por la variables 'classk'

```
data %>% group_by(classk) %>% summarise(n())
```

```

# A tibble: 3 x 2
  classk      `n()`
  <chr>      <int>
1 regular      2000
2 regular.with.aide 2015
3 small.class    1733

```

Consideramos el promedio:

```
data %>% group_by(classk) %>% summarise(mean(tmathssk))
```

```

# A tibble: 3 x 2
  classk      `mean(tmathssk)`
  <chr>          <dbl>
1 regular      483.
2 regular.with.aide 483.
3 small.class    491.

```

Uniones

Corresponde a la interacción entre dos tablas por al menos una llave. Traemos el set de datos districts:

1. Leemos el archivo districts:

```
# Define the URL for the raw CSV file
url <- "https://raw.githubusercontent.com/stringfesta/advancing-into-analytics-book/main/data"

# Get the data from the URL
response <- httr::GET(url)

# Ensure the response status is 200 (OK)
if (response$status_code == 200) {
  # Read data directly from the raw binary content into a CSV format
  temp_file <- tempfile(fileext = ".csv")
  writeBin(httr::content(response, "raw"), temp_file)
  data_01 <- read.csv(temp_file) # Change to read.csv for CSV files
  # Optionally, delete the temporary file after reading
  unlink(temp_file)
  # Use the data
  print(head(data_01))
} else {
  print("Failed to download file: HTTP status code is not 200")
}
```

	schidkn	school_name	county
1	1	Rosalia	New Liberty
2	2	Montgomeryville	Topton
3	3	Davy	Wahpeton
4	4	Steelton	Palestine
5	6	Tolchester	Sattley
6	7	Cahokia	Sattley

2. Unimos los dos data sets:

```
data %>% left_join(data_01, by = "schidkn")
```

A tibble: 5,748 x 10

	tmathssk	treadssk	classk	totexpk	sex	freelunk	race	schidkn	school_name
	<dbl>	<dbl>	<chr>	<dbl>	<chr>	<chr>	<chr>	<dbl>	<chr>
1	473	447	small.cla~	7	girl	no	white	63	Ridgeville
2	536	450	small.cla~	21	girl	no	black	20	South Heig~
3	463	439	regular.w~	0	boy	yes	black	19	Bunnlevel
4	559	448	regular	16	boy	no	white	69	Hokah
5	489	447	small.cla~	5	boy	yes	white	79	Lake Mathe~
6	454	431	regular	8	boy	yes	white	5	<NA>
7	423	395	regular.w~	17	girl	yes	black	16	Calimesa
8	500	451	regular	3	girl	no	white	56	Lincoln He~
9	439	478	small.cla~	11	girl	no	black	11	Moose Lake
10	528	455	small.cla~	10	girl	no	white	66	Siglerville

i 5,738 more rows

i 1 more variable: county <chr>

Generamos un agrupamiento considerando el join aplicado:

```
data %>% left_join(data_01, by = "schidkn") %>% group_by(county) %>% summarise(n())
```

```
# A tibble: 18 x 2
  county      `n()`
  <chr>      <int>
1 Belmar      393
2 Corunna     269
3 Edmore      176
4 Gallipolis  236
5 Grand Blanc 293
6 Imbery      130
7 Mabie       259
8 Manteca     432
9 New Liberty 315
10 Palestine  466
11 Reddell    262
12 Sattley    384
13 Selmont    664
14 Sugar Mountain 383
15 Summit Hill 332
16 Topton     407
17 Wahpeton   288
18 <NA>        59
```

Otra forma de hacer esto:

```
data_join = data %>% left_join(data_01, by = "schidkn")
```

```
data_join %>% group_by(county) %>% summarise(n())
```

```
# A tibble: 18 x 2
  county      `n()`
  <chr>      <int>
1 Belmar      393
2 Corunna     269
3 Edmore      176
4 Gallipolis  236
5 Grand Blanc 293
6 Imbery      130
7 Mabie       259
8 Manteca     432
9 New Liberty 315
10 Palestine  466
11 Reddell    262
12 Sattley    384
13 Selmont    664
14 Sugar Mountain 383
15 Summit Hill 332
16 Topton     407
```

17 Wahpeton	288
18 <NA>	59

Tipos de Join

Uniones: llave primaria y foránea

En SQL, se habla principalmente de llaves en el sentido de columnas que nos permitan unir dos bases. Intentamos realizar un metodo que mantenga la integridad de la tabla a la cual añadiré información.

Una llave primaria corresponde a la columna de la base a la cual yo deseo unir otra columna, usando como punto de interacción una llave foránea.

Consideremos las dos bases, en donde A corresponde a la llave primaria y B corresponde a la base foránea de cada una de las bases:

A	B
1	3
2	4
3	5
4	6

¿Qué valores se repiten dentro de cada llave?

Una complejidad de las uniones en SQL, corresponde a los requisitos que se deben cumplir para poder realizar uniones entre bases. Por ejemplo, una particularidad es que la llave primaria no debe tener valores repetidos y esto se repite en programas como RStudio. Por otra parte, Excel al utilizar funciones de manera individual (celda por celda), no posee dicho problema.

Veamos ahora distintos tipos de uniones que pueden generarse.

- Inner Join: Refiere a la unión en base a intersecciones.

A	B
3	3
4	4

- Outer Join: Refiere a la unión de todas las columnas en A y todas las columnas en B. Las celdas sin correlativo en la otra base, generarán un valor nulo.

A	B
1	NULL
2	NULL
3	3
4	4
NULL	5
NULL	6

Esto tipo de unión, puede tener dos variaciones:

- Outer Join > Left Outer Join: Predominan las columnas en A, y las comunes en B.

A	B
1	NULL
2	NULL
3	3
4	4

En Rstudio solo se conoce como Left Join.

- Outer Join > Right Outer Join: Predominan las columnas en B, y las comunes en A.

A	B
3	3
4	4
NULL	5
NULL	6

En Rstudio solo se conoce como Right Join.

Aplicación práctica de uniones

Set de datos

Considere que se tiene un set de datos `data_uniones.xlsx`, que contiene 4 tablas:

- Flights: Corresponde a distintos identificadores de vuelos por ruta.
- Routes: Rutas de vuelos.
- Aircraft: Tipos de aviones.
- Airports: Set de datos descriptor de aeropuertos en USA.

Import - Tidy - Transform

- ¿Cuáles son las variables de cada set de datos?

Por ejemplo, ¿qué es FuelCostperSeatMile (Cents)? Pero una pregunta más general es, ¿por qué es relevante aprender estos conceptos?

- ¿Se observa algún error en los datos?

Fijemonos en el formato de la fecha.

- ¿Posee la estructura correcta el set de datos?

No se ven errores; en las filas están las observaciones y en las columnas las variables. No existen formatos, ni celdas combinadas.

- ¿Existe identificadores únicos en los set de datos?

Existen múltiples identificadores únicos.

Se debe intentar llegar al análisis relevante del set de datos. En el caso de este set datos, claramente se puede llegar a un set de datos más completo.

- ¿Cuál es el set de datos que debe mantenerse? Veamos alguna manera de llegar a dicha conclusión.

Por último, se puede pensar en la inclusión de datos a la base de datos, que podrían ser de algún interés. En este caso intentaremos agregar los siguientes datos:

[Acá](#)

Hasta este punto, aún no hemos terminado con dicho procedimiento de **batallar con los datos**.

Antes de aplicar la unión de datos, sería bueno poder diagramar la relación que existe entre cada base datos. Acá debemos abordar un contenido relacionado.

Modelo de datos

Corresponde a una serie de conceptos que pueden utilizarse para describir un conjunto de datos y las operaciones relacionadas para su manipulación.

En la actualidad el modelo de bases de datos más utilizado corresponde al modelo relacional, que se define como el intento de obtener datos de distintas fuentes a través de relaciones o consultas que se basan en llaves (o columnas) que permiten la relación entre las distintas tablas. Esto quiere decir,

que no necesariamente se tiene una **base gigante**, sino que se tiene la opción de acceder a bases pequeñas que pueden ir complementando los análisis.

Modelo Relacional

Las entidades y relaciones se representan en formas de tablas.

- Las tablas son las relaciones.
- Las filas (tuplas) contienen datos sobre cada entidad.
- Las columnas corresponden a atributos de las entidades.

Se pretende determinar operaciones a realizar: Unión, intersección, diferencia, producto cartesiano, selección, proyección, reunión, etc.

Por otra parte, existen restricciones de integridad de entidad como también de integridad referencial (relacionado con el tema de llaves que vimos anteriormente).

Por ejemplo:

Entidades	Proveedor	Pieza
Atributos	Código	Código
	Nombre	Nombre
	Ciudad	Dimensiones Peso

En donde:

Relación	Suministra
Entidades Participantes	Proveedor - Pieza
Cardinalidad	Muchos a muchos
Atributos	Cantidad

De manera más específica, el modelo entidad/relación corresponde a la técnica basada en la identificación de las entidades y de las relaciones que se dan entre ellas, según la realidad que se intenta modelar.

Se debe recordar acá, el concepto de llave del que hablamos la clase pasada. Una llave (o también llamada clave), corresponde a un conjunto de atributos que permite identificar unívocamente a una entidad dentro de un conjunto de entidades.

Por ejemplo para una Facultad el modelo podría ser:

Entidades	Asignatura	Alumno	Profesor	Departamento	Aula	Grupo
Atributos	ID	RUT	RUT	ID	ID	ID
	Nombre	Nombre	Nombre	Nombre	Capacidad	Tipo
	Créditos	Dirección	Categoría			
	Curso	Email	Email			

En donde existen las siguientes relaciones:


Relación	Entidades participantes	Cardinalidad	Atributos
se matricula en	Alumno - Grupo	N:M	Calificación
enseña	Profesor - Grupo	N:M	
impartida en	Asignatura - Grupo	1:N	
asignada a	Aula - Grupo	N:M	Día, hora
pertenece a	Profesor - Departamento	N:1	
dirige	Profesor - Departamento	1:1	

Esto también puede ser representado de manera grafica. Veamos el siguiente ejemplo:


Order Line	
int	Order_ID
int	Line_number
int	Order_item
int	Quantity
decimal	Price



Order	
int	Order_ID
string	Customer
string	Sales_person
date	Order_date
date	Requested_ship_date
string	Status



Person	
int	Person_ID
string	Name
string	E_mail
string	Street



Item	
int	Item_ID
string	Item_Name
string	Description

Veamos esto en relación a los datos que estuvimos revisando; primero debemos ingresar las tablas sobre las que estuvimos trabajando.

```
library(readxl)

flights_01 <- read_excel("data/data_uniones.xlsx",
                        sheet = "Flights")

routes_01 <- read_excel("data/data_uniones.xlsx",
                       sheet = "Routes")

airports_01 <- read_excel("data/data_uniones.xlsx",
                         sheet = "Airports")

aircraft_01 <- read_excel("data/data_uniones.xlsx",
                        sheet = "Aircraft")
```

aircraft_01	
numeric	AircraftID
character	AircraftType
numeric	SeatCapacity
numeric	FuelCostperSeatMile

airports_01	
character	AirportID
character	AirportName
numeric	Gates

Después debemos generar las relaciones entre cada una de las tablas:

airports_01		
character	AirportID	PK
character	AirportName	
numeric	Gates	



routes_01		
character	RouteID	PK
character	DepAirport	
character	AirportID	FK
numeric	Distance	
numeric	ListPrice	



aircraft_01		
numeric	AircraftID	PK
character	AircraftType	
numeric	SeatCapacity	
numeric	FuelCostperSeatMile	



flights_01		
character	FlightID	PK
character	Date	
character	RouteID	FK
numeric	DepartureDelay	
numeric	AircraftID	FK
numeric	ScheduledDeparture	
numeric	AvgTicketPrice	

Podemos intentar mejorar un poco el formato de la visualización:

