

Limpieza y Exploración de Datos

Actividad 01: Comparación Manual vs Asistido con IA

Sebastián Egaña Santibáñez (segana@fen.uchile.cl)

Nicolás Leiva Díaz (nleivad@fen.uchile.cl)

2026-09-10

Descargas

Introducción: La Actividad de Limpieza de Datos

Contexto: Tienes un dataset sobre estadísticas de mujeres en ajedrez de diferentes federaciones mundiales. Tu tarea es:

1. Cargar datos desde Excel
2. Crear un diccionario de variables
3. Realizar estadística descriptiva
4. Limpiar y estandarizar variables
5. Crear nuevas variables si es necesario
6. Entregar un reporte con explicaciones

Pregunta pedagógica: ¿Cómo acelerar este flujo sin sacrificar calidad?

Enfoque 1: Manual (Tradicional)

Paso 1: Cargar librerías y datos

Sin IA, escribirías el código manualmente:

```
# Cargar librerías
library(readxl)
library(tidyverse)
library(skimr)

# Cargar datos
data <- read_excel("chess_women.xlsx", sheet = "data")
variables_dict <- read_excel("chess_women.xlsx", sheet = "variables")

# Ver estructura
head(data)
str(data)
```

Tiempo invertido: ~5 minutos (recordar sintaxis, buscar ayuda si olvidas argumentos).

Paso 2: Exploración Manual

```
# Diccionario manual
print(variables_dict)

# Estadística descriptiva manual
summary(data)
skim(data)

# Buscar valores faltantes
data %>%
  summarise(across(everything(), ~sum(is.na(.))))

# Visualizar distribuciones
data %>%
  pivot_longer(everything()) %>%
```

```
ggplot(aes(x = value)) +
  geom_histogram() +
  facet_wrap(~name, scales = "free")
```

Tiempo invertido: ~15 minutos (prueba y error, ajustes visuales).

Paso 3: Limpieza y Transformación Manual

```
# Estandarizar nombres
data_clean <- data %>%
  rename_all(tolower) %>%
  rename_all(~gsub(" ", "_", .))

# Detectar y manejar valores atípicos
data_clean <- data_clean %>%
  mutate(
    ranking = as.numeric(ranking),
    age = as.numeric(age),
    rating = as.numeric(rating)
  )

# Crear nuevas variables
data_clean <- data_clean %>%
  mutate(
    rating_category = case_when(
      rating >= 2300 ~ "Grandmaster",
      rating >= 2200 ~ "Master",
      rating >= 2000 ~ "Expert",
      TRUE ~ "Other"
    ),
    age_group = cut(age, breaks = c(0, 20, 30, 40, 50, 100),
                    labels = c("<20", "20-30", "30-40", "40-50", "50+"))
  )
```

Tiempo invertido: ~20 minutos (ajustes iterativos, decisiones ad-hoc).

Paso 4: Generar Reporte Manual

```
# Crear resumen
resumen <- data_clean %>%
  group_by(rating_category, age_group) %>%
  summarise(
    n = n(),
```

```
    mean_rating = mean(rating, na.rm = TRUE),  
    sd_rating = sd(rating, na.rm = TRUE)  
  )  
  
# Guardar en archivo  
write.csv(resumen, "resumen_limpieza.csv")
```

Tiempo total aproximado: 50-60 minutos (incluyendo debugging, consultas, retoques).

Enfoque 2: Asistido con Claude Code

Estrategia: Describe qué necesitas en lenguaje natural

En lugar de escribir código línea por línea, describes la tarea a Claude Code:

Prompt al asistente:

“Necesito limpiar un dataset de ajedrez desde Excel. - Carga dos hojas: ‘data’ y ‘variables’
- Crea un reporte que incluya: 1. Diccionario de variables (nombre, tipo, descripción) 2. Estadística descriptiva completa 3. Detección de valores faltantes y atípicos 4. Estandarización de nombres de columnas 5. Nuevas variables: categoría de rating (GM, Master, Expert, Otros) y grupos de edad 6. Visualizaciones de distribuciones - Exporta todo a un archivo de reporte HTML”

Lo que Claude Code genera automáticamente

Claude Code crearía un script completo optimizado:

```
library(readxl)
library(tidyverse)
library(skimr)

# 1. CARGAR DATOS
data <- read_excel("chess_women.xlsx", sheet = "data")
variables_dict <- read_excel("chess_women.xlsx", sheet = "variables")

# 2. DICCIONARIO DE VARIABLES
var_dict_formatted <- variables_dict %>%
  rename(
    "Variable" = starts_with("nombre") | starts_with("Nombre"),
    "Tipo" = starts_with("tipo") | starts_with("Tipo"),
    "Descripción" = starts_with("descr") | starts_with("Descr")
  )

# 3. ESTADÍSTICA DESCRIPTIVA
skim_stats <- skim(data)
summary_stats <- data %>%
```

```

summarise(across(where(is.numeric),
  list(
    n = ~n(),
    mean = ~mean(., na.rm = TRUE),
    sd = ~sd(., na.rm = TRUE),
    min = ~min(., na.rm = TRUE),
    q25 = ~quantile(., 0.25, na.rm = TRUE),
    median = ~median(., na.rm = TRUE),
    q75 = ~quantile(., 0.75, na.rm = TRUE),
    max = ~max(., na.rm = TRUE),
    missing = ~sum(is.na(.))
  ),
  .names = "{.col}_{.fn}"
))

# 4. VALORES FALTANTES
missing_report <- data %>%
  summarise(across(everything(),
    ~paste(sum(is.na(.)), "de", n(), "valores faltantes")))

# 5. LIMPIEZA Y ESTANDARIZACIÓN
data_clean <- data %>%
  rename_all(tolower) %>%
  rename_all(~gsub(" ", "_", .)) %>%
  mutate(across(where(is.character), str_trim))

# 6. NUEVAS VARIABLES
data_clean <- data_clean %>%
  mutate(
    rating_numeric = as.numeric(rating),
    age_numeric = as.numeric(age),
    rating_category = case_when(
      rating_numeric >= 2300 ~ "Grandmaster",
      rating_numeric >= 2200 ~ "Master",
      rating_numeric >= 2000 ~ "Expert",
      TRUE ~ "Otro"
    ),
    age_group = cut(age_numeric,
      breaks = c(0, 20, 30, 40, 50, 100),
      labels = c("<20", "20-30", "30-40", "40-50", "50+"))
  )

# 7. VISUALIZACIONES
plot_rating_dist <- data_clean %>%
  ggplot(aes(x = rating_numeric)) +
  geom_histogram(binwidth = 50, fill = "#FF0000", alpha = 0.7) +
  labs(title = "Distribución de Ratings",

```



```

    x = "Rating", y = "Frecuencia") +
  theme_minimal()

plot_age_dist <- data_clean %>%
  ggplot(aes(x = age_numeric)) +
  geom_histogram(binwidth = 5, fill = "#0066CC", alpha = 0.7) +
  labs(title = "Distribución de Edades",
        x = "Edad", y = "Frecuencia") +
  theme_minimal()

# 8. RESUMEN POR CATEGORÍAS
summary_by_category <- data_clean %>%
  group_by(rating_category, age_group) %>%
  summarise(
    n = n(),
    mean_rating = mean(rating_numeric, na.rm = TRUE),
    sd_rating = sd(rating_numeric, na.rm = TRUE),
    mean_age = mean(age_numeric, na.rm = TRUE),
    .groups = 'drop'
  )

# 9. EXPORTAR RESULTADOS
write.csv(summary_by_category, "resumen_limpieza.csv", row.names = FALSE)

```

Ventajas del Enfoque Asistido

Aspecto	Manual	Con IA
Tiempo de código	50-60 min	5-10 min
Boilerplate	Completo (cargas, librerías)	Generado automáticamente
Cobertura	A menudo incompleta (olvidas casos)	Exhaustiva
Documentación	Manual, lleva tiempo	Generada con explicaciones
Iteraciones	Reescribir cada cambio	Pedir cambios en lenguaje natural
Debugging	Lees mensajes de error solo	Asistente explica y propone soluciones

Comparación en Tiempo Real

Escenario: “Quiero visualizar age_group vs rating_category”

Manual (Sin IA)

```
# Buscas en Google, Stack Overflow, recuerdas sintaxis de ggplot
# Pruebas varios geoms (bar, tile, violin)
# Ajustas colores, temas, etiquetas

data_clean %>%
  ggplot(aes(x = age_group, y = rating_category, fill = n())) +
  geom_tile() +
  # ... (10 minutos de ajustes)
```

Tiempo: ~15 minutos

Con IA

Prompt: "Dame un gráfico de tiles que muestre age_group vs rating_category, con conteos en color y etiquetas claras"

Claude Code genera el código optimizado **en segundos**. Solo ajustas si necesitas.

Tiempo: ~2 minutos (incluido ajuste)

Actividad para Estudiantes: Tu Turno

Instrucciones (Con IA)

Opción A: Maximalista (Recomendada para aprender)

Paso 1: Prepara tu workspace - Abre Positron - Crea un proyecto nuevo - Descarga el dataset `chess_women.xlsx`

Paso 2: Usa Claude Code para exploración inicial

Abre Claude Code en Positron y pide:

“Carga `chess_women.xlsx` y dame un resumen inicial: - Dimensiones del dataset - Tipos de datos - Valores faltantes por columna - Top 5 filas”

Paso 3: Itera sobre la limpieza

“Ahora estandariza los nombres de columnas (tolower, sin espacios), convierte campos numéricos si es necesario, y crea estas variables: - `rating_elite`: TRUE si `rating` ≥ 2200 - `years_active`: diferencia entre max y min de año”

Paso 4: Visualiza resultados

“Crea 3 gráficos: 1. Distribución de ratings (histogram) 2. Rating por país (top 10) 3. Correlación entre edad y rating”

Paso 5: Genera reporte

“Exporta a un archivo HTML con: - Tabla de diccionario de variables - Resumen estadístico por país - Los 3 gráficos anteriores”

Opción B: Enfoque Híbrido (Equilibrado)

Si prefieres un balance entre escribir código y usar IA:

1. Carga datos manualmente en R
 2. Usa Claude Code para la estandarización compleja
 3. Visualiza usando `ggplot2` (escribes el esquema básico, IA refina)
 4. Genera reporte en Quarto (mezcla de código propio + IA)
-

Opción C: Minimalista (Enfoque “Prompt-Driven”)

Pídele a Claude Code **todo el flujo** en un único prompt largo:

“Necesito un análisis completo de chess_women.xlsx: 1. Carga ambas hojas 2. Crea diccionario de variables 3. Estadística descriptiva (mean, sd, missing) 4. Estandarización de nombres y tipos 5. Variables nuevas: elite (rating $\geq$ 2200), years_active 6. Visualizaciones: 3-5 gráficos clave 7. Resumen por país/región 8. Exporta reporte HTML completo”

Nota: Claude Code puede generar 300+ líneas de código pulido en ~1 **minuto**.

Rúbrica de Evaluación

Criterio	Excelente	Bueno	Aceptable
Carga de datos	Ambas hojas cargadas, validadas	Cargadas correctamente	Cargadas con warning
Diccionario de variables	Completo, tipos correctos, descripciones claras	Completo, tipos ok	Incompleto
Estadística descriptiva	Completa (mean, sd, quantiles, missing)	Cubiertos principales	Solo summary()
Limpieza y estandarización	Nombres normalizados, tipos correctos, sin inconsistencias	Nombres limpios, tipos mayormente ok	Parcial
Variables nuevas	2+ variables útiles, bien justificadas	1 variable clara	Ninguna o trivial
Visualizaciones	3+ gráficos informativos, leyendas claras	2 gráficos ok	1 gráfico o pobre
Documentación/Reporte	Reporte HTML/PDF claro, código comentado	Reporte básico, algunas notas	Mínimo o ausente
Uso de IA	Aprovecha Claude Code bien, itera claramente	Usa IA para partes, código propio para otras	Mínimo uso de IA

Entrega

Debes entregar:

1. **Script R** (actividad_01_limpieza.R o .qmd) con código comentado
2. **Dataset limpio** (chess_women_clean.csv)
3. **Reporte HTML o PDF** con:
 - Diccionario de variables (tabla formateada)
 - Resumen estadístico (por país, por edad, por rating)

- Mínimo 3 visualizaciones
 - Explicación de decisiones de limpieza
-

Ejemplo de Lo Que Genera Claude Code (Real)

Prompt enviado:

"Dataset de ajedrez, quiero age_group (20-30, 30-40, 40-50, 50+)
y contar jugadoras por grupo"

Código generado (segundos después):

```
data_clean <- data_clean %>%
  mutate(age_group = case_when(
    age >= 20 & age < 30 ~ "20-30",
    age >= 30 & age < 40 ~ "30-40",
    age >= 40 & age < 50 ~ "40-50",
    age >= 50 ~ "50+",
    TRUE ~ NA_character_
  ))

count_by_age <- data_clean %>%
  group_by(age_group) %>%
  summarise(n = n(), .groups = 'drop') %>%
  arrange(desc(n))

print(count_by_age)
```

Sin IA: Escribirías esto mismo en ~5 minutos. **Con IA:** 10 segundos, listo.

Reflexión Final: IA como Herramienta, No Reemplazo

Usa IA para:

- **Boilerplate:** cargas, librerías, transformaciones estándar
- **Exploración:** prueba múltiples enfoques rápidamente
- **Debugging:** “¿por qué falla este argumento?”
- **Documentación:** genera comentarios y explicaciones
- **Refactorización:** “limpia este código”

NO uses IA para:

- **Decisiones financieras:** tú eliges qué variable crear, IA genera código
- **Validación:** verifica resultados siempre (no confíes ciegamente)
- **Comprensión:** entiende el código generado antes de usarlo
- **Pensar:** IA acelera la ejecución, no la estrategia

La Mentalidad Correcta

“IA es como un copiloto competente: genera código, pero **TÚ** diriges el análisis.”

Recursos Adicionales

[Claude Code Docs](#)

[Positron IDE](#)

[tidyverse en R](#)

[Mejores prácticas en Finanzas Cuantitativas](#)